

## 基于 SGICP 的点云尺度估计及配准算法

林宝尉<sup>1,2</sup> 王法胜<sup>3</sup> 孙 怡<sup>1</sup>

<sup>1</sup>(大连理工大学 辽宁 大连 116023)

<sup>2</sup>(大连东软信息学院 辽宁 大连 116023)

<sup>3</sup>(大连民族大学 辽宁 大连 116600)

**摘 要** 针对不同尺度的点云配准,提出一种扩展的 GICP 方法。GICP 方法是一种面对面的配准策略,通过计算每次迭代中各变量的导数,快速地实现最优变换矩阵计算。提出的算法是通过增加尺度变量来扩展 GICP 的功能,并给出详细的尺度变量的推导公式。实验结果证明,该方法可以有效地对室内和室外不同尺度点云进行配准以及尺度估计。

**关键词** GICP 点云 尺度估计 点云配准

中图分类号 TP391

文献标识码 A

DOI:10.3969/j.issn.1000-386x.2018.05.036

## SGICP-BASED POINT CLOUD SCALE ESTIMATION AND ALIGNMENT ALGORITHM

Lin Baowei<sup>1,2</sup> Wang Fasheng<sup>3</sup> Sun Yi<sup>1</sup>

<sup>1</sup>(Dalian University of Technology, Dalian 116023, Liaoning, China)

<sup>2</sup>(Dalian Neusoft University of Information, Dalian 116023, Liaoning, China)

<sup>3</sup>(Dalian Minzu University, Dalian 116600, Liaoning, China)

**Abstract** For the point cloud alignment with different scales, an extended GICP method was proposed. The GICP method was a face-to-face registration strategy. By calculating the derivative of each variable in each iteration, the optimal transformation matrix can be calculated quickly. The algorithm proposed in this paper extent the function of GICP by increasing the scale variables, and gave detailed derivation formulas for scale variables. Experimental results showed that this method can effectively align and scale the indoor and outdoor point clouds at different scales.

**Keywords** GICP Point cloud Scale estimation Point cloud alignment

## 0 引 言

近年来各种 3D 获取设备及方法都在迅速的发展,比如常见的 range finder、激光雷达(LiDAR)、运动结构提取、机构光投影及 Kinect 等。作为 3D 真实场景的重要表现形式,3D 点云已经在众多的研究及应用领域,如计算机视觉、机器人及无人驾驶中被使用。

和 2D 图片以及 3D 曲面不同,点云是一种更自然的对真实场景的描述。其不需要额外的要素间连接关系及其他复杂的拓扑结构。然而,如果在获取点云信

息时使用了不同的设备或者复原方法,生成的点云一般会存在闭塞点、杂波、噪声、表面稀疏度以及尺度不同等各种问题。其中尺度不同的问题在不同种点云融合时尤其需要解决。

近些年,部分学者提出了多种用来估计点云尺度并且进行点云配准的方法。一般的,这些方法可以分为基于 ICP(Iterative Closest Point)的配准方法、基于特征匹配的方法和其他方法。

基于 ICP 的方法:ICP 方法最早由 Besl 等<sup>[1]</sup>提出,是使用最广泛的点云配准方法。该方法主要包括两个计算步骤:

- (1) 在每一次迭代,寻找最近邻的点;
- (2) 计算该次迭代的变换矩阵并计算尺度比。

这种在 20 世纪 60 年代提出的点云变化矩阵计算通常被称作 Orthogonal Procrustes 问题<sup>[2-3]</sup>,其不仅适用于刚性问题,通过相似变换矩阵的推定,该方法也可以用于非刚性问题。ICP 方法在配准点云的同时,也可以对两点云间的相对尺度比例进行推定。然而,ICP 的一个最大的问题是需要提供给它一个位姿和尺度比例的初始猜测值。如果该猜测值距离全局最优解较远,最终的结果很有可能会收敛在一个局部的最优解,从而导致配准失败。

大量的基于 ICP 的扩展的方法被同时应用于点云的配准当中。这些方法被分为“point-to-point”<sup>[1]</sup>、“point-to-plane”<sup>[4-5]</sup>及“plane-to-plane”<sup>[6]</sup>三个种类。这些方法基本都可以解决点云的闭塞、杂波、噪声和表面稀疏等问题。但是它们并没有解决点云的尺度不同所带来的问题。

基于特征匹配的方法:和 ICP 方法不同,基于特征匹配的方法不需要提供初始位姿的猜测即可对点云进行配准。比较常用的方法有 spin image<sup>[7-8]</sup>、NARF<sup>[9]</sup>等。同样的,这些方法也没有解决点云尺度不同的问题。

Point Feature Histogram (PFH)<sup>[10]</sup>、Fast Point Feature Histogram (FPFH)<sup>[11]</sup>、3D Shape Context (3DSC)<sup>[12]</sup>、Rotational Projection Statistics (RoPS)<sup>[13]</sup>等流行的局部特征方法,虽然能够提高点云配准的鲁棒性。然而这些方法仍然无法解决点云的尺度变化问题,有的方法甚至无法应用于点云场景。

一些 3D 特征是尺度不变的方法,如 3D SIFT<sup>[14]</sup>、3D SURF<sup>[15]</sup>等。该类方法都是对 2D 方法的扩展,他们对 3D 曲面场景的效果比较好。由于点云无法提供表面的曲率信息,所以这类方法也是无法使用的。

不同于上述特征提取的方法,SHOT<sup>[16]</sup>和 SIFP 等<sup>[17-18]</sup>方法通过对场景纹理等信息的分析来描述局部特征。根据上述文献的描述,场景中纹理信息及法向量信息对于提高局部特征的鲁棒性具有很好的效果。他们对于闭塞点、杂波和噪声具有很好的鲁棒性。然而对于 3D 点云来说,由于不同的采集方法,额外的纹理等信息可能不存在。同时,3D 点云表面的法向量质量也对配准的结果起关键作用。

Huang<sup>[19]</sup>提出了一种基于深度学习的 3D 点云特征提取方法,并将提取的点云特征应用于多传感器点云的配准中。根据文献中的描述,该方法对于人工合成的数据具有很好的鲁棒性,但是仍未将该方法应用

于真实场景。Lin 等<sup>[20]</sup>提出了一种 3D 点云配准的方法。该方法是多种已有方法的整合,将 3D 点云的关键点提取,PCA 修正,深度神经网络特征描述以及 ICP 的精度调整整合到一起,得到了较鲁棒的配准结果。该方法对于大尺度场景的数据融合、定位等应用具有较好的效果。但是该方法没有将点云的尺度变化问题考虑进去。

其他方法:最简单的用来计算尺度的方法可以通过计算点云的边界值或是通过计算点云分布的标准差等。这些边界值或者标准差可以用来缩放点云,使点云间的尺度基本相同。但是,这种方法只有在点云完全相互重叠的时候才有效。

Elbaz 等<sup>[21]</sup>提出了一种基于 SVD 分解的 2D 特征辅助 3D 配准方法, Lin 等<sup>[22]</sup>提出了一种结合 2D 特征的 3D 特征提取方法。Aubry 等<sup>[23]</sup>提出了一种通过使用 3D 模型来检测 2D 物体的方法。Crivellaro 等<sup>[24]</sup>同样提出了一种基于 2D 图像来配准 3D 模型的方法。这些方法无法应用于本文所提出的场景之中。

Keyscale、ScaleRatioICP<sup>[25-26]</sup>是两种很好的尺度不同点云配准的方法。通过 PCA 贡献率来计算能够代表点云尺度的 key scale,并且计算两个点云间的相对尺度比来归一化点云大小。同时, Mellado 等<sup>[27]</sup>也提出了相对尺度比的计算方法来计算不同类型点云的结果。这些方法虽然可以估计出点云间的尺度信息,但是它们并不进行点云的配准操作。

在本文中,提出了一种新的点云配准及尺度估计的方法。该方法是 GICP 方法的一种扩展。在构建点云配准的成本函数时,将代表点云尺度的参数考虑进去。通过对该非线性问题求解来推定刚性变化的变换矩阵。该方法也称为 SGICP 方法。

## 1 SGICP 方法

本文提出的 SGICP 方法是 GICP (Generalized-ICP) 的扩展。在详细介绍 SGICP 方法之前,我们先来简单介绍 GICP 方法。

### 1.1 GICP

GICP 是对“point-to-point”ICP 和“point-to-plane”ICP 方法的扩展。为了提高配准的鲁棒性, GICP 使用点云表面的协方差矩阵来构建点云配准的成本函数。假设我们在两个 3D 点云中找到了互为近邻的两簇点:  $A = \{a_i | i = 1, 2, \dots, N\}$  和  $B = \{b_i | i = 1, 2, \dots, N\}$ , 其中  $a_i$  和  $b_i$  互相匹配。在概率论中,我们假设存在两簇互相对应的点  $\hat{A} = \{\hat{a}_i\}$  和  $B = \{\hat{b}_i\}$ 。所以,可以定义

点云通过下列高斯分布来生成:

$$\begin{cases} a_i \sim \mathcal{N}(\hat{a}_i, C_i^A) \\ b_i \sim \mathcal{N}(\hat{b}_i, C_i^B) \end{cases} \quad (1)$$

$C_i$  是每个点的协方差矩阵。

我们定义刚性变换矩阵为  $\mathbf{T}$ , 每一对对应点的配准误差  $d_i$  则为:

$$d_i = b_i - \mathbf{T}a_i \quad (2)$$

因为  $a_i$  和  $b_i$  属于互相独立的高斯分布, 则  $d$  的分布也属于高斯分布:

$$d_i \sim \mathcal{N}(0, C_i^B + \mathbf{T}C_i^A\mathbf{T}^T) \quad (3)$$

所以, 计算变换矩阵  $\mathbf{T}$  的成本函数为:

$$\mathbf{T} = \operatorname{argmin} \sum d_i^T (C_i^B + \mathbf{T}C_i^A\mathbf{T}^T)^{-1} d_i \quad (4)$$

## 1.2 SGICP

下面, 我们将介绍 SGICP 的详细推导。我们将继续使用 GICP 中定义的符号。

### 1.2.1 成本函数

我们的应用场景是要对不同尺度的点云进行配准和尺度估计。所以, 在计算对应点的配准误差  $d_i$  时, 我们加入了尺度变量  $s$ :

$$d_i = b_i - s\mathbf{T}a_i \quad (5)$$

因为我们可以将  $\mathbf{T}$  写成  $\mathbf{T} = [\mathbf{R}][\mathbf{t}]$ , 所以上式可写成:

$$d_i = b_i - s\mathbf{R}a_i - s\mathbf{t} \quad (6)$$

由于  $d_i$  服从高斯分布, 根据式(3)可以得到新的分布为:

$$\begin{aligned} d_i &\sim \mathcal{N}(b_i - s\mathbf{T}a_i, C_i^B + s\mathbf{T}C_i^A\mathbf{T}^T) \\ &\sim \mathcal{N}(0, C_i^B + s^2\mathbf{T}C_i^A\mathbf{T}^T) \end{aligned} \quad (7)$$

所以, 我们定义新的成本函数为:

$$f = \frac{1}{N} \sum d_i^T (C_i^B + s^2\mathbf{T}C_i^A\mathbf{T}^T)^{-1} d_i \quad (8)$$

### 1.2.2 推导证明

为了计算成本函数的最优化问题, 我们需要计算每一次迭代中变换矩阵的导数。假设最优的结果为  $\mathbf{T}^* = s\mathbf{T}$ 。为了对  $\mathbf{T}^*$  进行求导, 我们将  $\mathbf{T}^*$  分解为:

$$\mathbf{T}^* = s\mathbf{T}$$

$$\mathbf{T}^* = s[\mathbf{R}][\mathbf{t}]$$

$$\mathbf{T}^* = [s, x, y, z, \phi, \theta, \psi]^T \quad (9)$$

根据雅可比公式:

$$\frac{\partial f}{\partial \mathbf{T}^*} = \left[ \frac{\partial f}{\partial s}, \frac{\partial f}{\partial x}, \frac{\partial f}{\partial y}, \frac{\partial f}{\partial z}, \frac{\partial f}{\partial \phi}, \frac{\partial f}{\partial \theta}, \frac{\partial f}{\partial \psi} \right]^T \quad (10)$$

下面, 我们将给出  $f$  对  $s, x, y, z, \phi, \theta, \psi$  的偏导。

首先计算  $\nabla s$ :

$$\nabla s = \frac{\partial f}{\partial s} = \frac{1}{N} \sum \frac{\partial d_i^T (C_i^B + s^2\mathbf{T}C_i^A\mathbf{T}^T)^{-1} d_i}{\partial s} =$$

$$\frac{2}{N} \sum \frac{\partial d_i^T}{\partial s} (C_i^B + s^2\mathbf{T}C_i^A\mathbf{T}^T)^{-1} d_i =$$

$$\frac{2}{N} \sum \frac{\partial (b_i - s\mathbf{R}a_i - s\mathbf{t})^T}{\partial s} (C_i^B + s^2\mathbf{T}C_i^A\mathbf{T}^T)^{-1} d_i =$$

$$\frac{2}{N} \sum (-\mathbf{R}a_i - \mathbf{t})^T (C_i^B + s^2\mathbf{T}C_i^A\mathbf{T}^T)^{-1} d_i \quad (11)$$

接下来计算  $\nabla x, \nabla y, \nabla z$ :

$$\nabla x = \frac{\partial f}{\partial x} = \frac{1}{N} \sum \frac{\partial d_i^T (C_i^B + s^2\mathbf{T}C_i^A\mathbf{T}^T)^{-1} d_i}{\partial x} =$$

$$\frac{2}{N} \sum \frac{\partial d_i^T}{\partial x} (C_i^B + s^2\mathbf{T}C_i^A\mathbf{T}^T)^{-1} d_i =$$

$$\frac{2}{N} \sum \frac{\partial (b_i - s\mathbf{R}a_i - s\mathbf{t})^T}{\partial x} (C_i^B + s^2\mathbf{T}C_i^A\mathbf{T}^T)^{-1} d_i =$$

$$\frac{2}{N} \sum (s)^T (C_i^B + s^2\mathbf{T}C_i^A\mathbf{T}^T)^{-1} d_i =$$

$$\frac{2s}{N} \sum (C_i^B + s^2\mathbf{T}C_i^A\mathbf{T}^T)^{-1} d_i \quad (12)$$

相似地有:

$$\nabla y = \frac{\partial f}{\partial y} = \frac{2s}{N} \sum (C_i^B + s^2\mathbf{T}C_i^A\mathbf{T}^T)^{-1} d_i \quad (13)$$

$$\nabla z = \frac{\partial f}{\partial z} = \frac{2s}{N} \sum (C_i^B + s^2\mathbf{T}C_i^A\mathbf{T}^T)^{-1} d_i \quad (14)$$

最后计算  $\nabla \phi, \nabla \theta, \nabla \psi$ :

$$\nabla \phi = \frac{\partial f}{\partial \phi} = \frac{1}{N} \sum \frac{\partial d_i^T (C_i^B + s^2\mathbf{T}C_i^A\mathbf{T}^T)^{-1} d_i}{2\phi} =$$

$$\frac{2}{N} \sum \frac{\partial d_i^T}{\partial \phi} (C_i^B + s^2\mathbf{T}C_i^A\mathbf{T}^T)^{-1} d_i =$$

$$\frac{2}{N} \sum \frac{\partial (b_i - s\mathbf{R}a_i - s\mathbf{t})^T}{\partial \phi} (C_i^B + s^2\mathbf{T}C_i^A\mathbf{T}^T)^{-1} d_i =$$

$$- \frac{2s}{N} \sum a_i^T (d\mathbf{R}_\phi)^T (C_i^B + s^2\mathbf{T}C_i^A\mathbf{T}^T)^{-1} d_i =$$

$$- \frac{2s}{N} \sum \operatorname{tr}[(d\mathbf{R}_\phi)^T (C_i^B + s^2\mathbf{T}C_i^A\mathbf{T}^T)^{-1} d_i a_i^T] =$$

$$- \operatorname{tr}\left[\frac{2s}{N} \sum a_i (C_i^B + s^2\mathbf{T}C_i^A\mathbf{T}^T)^{-1} d_i^T, d\mathbf{R}_\phi\right] =$$

$$- \left(d\mathbf{R}_\phi, \frac{2s}{N} \sum a_i (C_i^B + s^2\mathbf{T}C_i^A\mathbf{T}^T)^{-1} d_i^T\right) \quad (15)$$

相似地有:

$$\nabla \theta = \frac{\partial f}{\partial \theta} = - \left(d\mathbf{R}_\theta, \frac{2s}{N} \sum a_i (C_i^B + s^2\mathbf{T}C_i^A\mathbf{T}^T)^{-1} d_i^T\right) \quad (16)$$

$$\nabla \psi = \frac{\partial f}{\partial \psi} = - \left(d\mathbf{R}_\psi, \frac{2s}{N} \sum a_i (C_i^B + s^2\mathbf{T}C_i^A\mathbf{T}^T)^{-1} d_i^T\right) \quad (17)$$

这里的  $d\mathbf{R}_\psi = \frac{d\mathbf{R}}{d\phi}, d\mathbf{R}_\theta = \frac{d\mathbf{R}}{d\theta}, d\mathbf{R}_\psi = \frac{d\mathbf{R}}{d\psi}$ 。

最后, 通过更新  $s, x, y, z, \phi, \theta, \psi$  实现梯度下降算法并计算最优的变化矩阵:

$s$

$x$

$y$

$z$

$\phi$

$\theta$

$\psi$

$_{n+1}$

$s$

$x$

$y$

$z$

$\phi$

$\theta$

$\psi$

$_{n+1}$

$\nabla s$

$\nabla x$

$\nabla y$

$\nabla z$

$\nabla \phi$

$\nabla \theta$

$\nabla \psi$

$=$

$-$

$\nabla s$

$\nabla x$

$\nabla y$

$\nabla z$

$\nabla \phi$

$\nabla \theta$

$\nabla \psi$

$(18)$

2 实验结果及分析

我们将通过实验证明文中提出的算法可以有效地应用于人工以及真实场景数据。

2.1 人工场景数据

为演示 SGICP 算法,首先应用于简单的人工数据。该数据是斯坦福的兔子 3D 点云模型,可以从文献[28]下载。如图 1(a)所示,图中右边的兔子是原始点云,含有 69 450 个点。图 1(a)中左边的兔被放大 1.5 倍,并对点数进行随机下采样,得到点数为 543 652 的新模型。该点云中并没有明显的面元素,但是由于两点云可以互相重叠,所以 SGICP 可以有效实现点云的尺度估计和点云配准。配准的结果如图 1(b)所示。两点云可以完整重叠在一起。点云尺度估计的结果为 1.500 01(表 1 所示)。使用 GICP 失败的配准结果如果图 1(c)所示。



图 1 原始兔子点云及配准结果

在图 1 的实验基础上,我们在点云中加入了随机噪声。高斯噪音被随机的加入了点云中每个 3D 点的 x、y、z 坐标。高斯均值量分别设置为点云边界长度的 0.1%、0.5% 和 1.0%。同时,两个点云都随机地被删除 80% 的 3D 点。点云配准的结果如图 2 和表 1 所示,SGICP 可以得到正确的配准结果。



图 2 加入噪声后的兔子点云及配准结果

表 1 不同数据的尺度估计结果,括号中数字为相对误差

数据	ICP	GICP	SGICP
原始兔子	1.499 99 (0.00%)	failed	1.500 01(0.00%)
噪声兔子(0.1%)	1.495 33 (0.31%)	failed	1.500 43(0.03%)
噪声兔子(0.5%)	1.496 73 (0.22%)	failed	1.499 85(0.01%)
噪声兔子(1%)	1.490 87 (0.61%)	failed	1.495 62(0.29%)
真实场景	0.897 536 (28.22%)	failed	0.700 78(0.11%)

我们同时将该算法应用到斯坦福的 Happybuddy 及 Airplane 数据中。准确的配准结果如图 3、图 4 所示。




图 3 Happy buddy 点云配准结果




图 4 Airplane 点云及配准结果

2.2 真实场景数据

真实场景数据采集于 Velodyne 32E 激光。我们将激光器安装于汽车顶部,并将激光整体倾斜一定的角度,翻滚角、俯仰角和偏航角分别设置为  $6.0^{\circ}$ 、 $36.0^{\circ}$  和  $-91.0^{\circ}$ 。当汽车在城市街角场景中行驶并采集点云时,我们连续采集两帧数据。点云如图 5(a) 所示,其中一帧点云被缩放为原始的 0.7 倍。基于 SGICP 方法配准的正确结果如图 5(d) 所示。同时,我们得到的点云的尺度比为 0.700 78 (表 1 所示)。

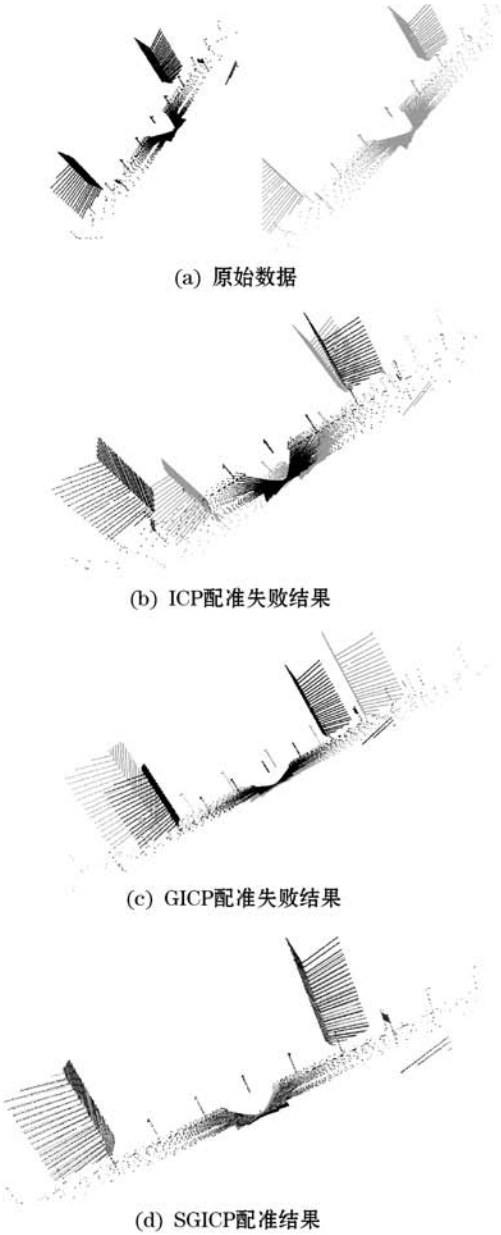


图5 Velodyne32E 激光点云及配准结果

SGICP 和 ICP、GICP 的对比结果显示在图 5(b, c) 中。图 6 给出了 SGICP 和 ICP 方法的优化速度对比,由于 SGICP 使用扩展牛顿法(BFGS)进行优化,其收敛速度比 ICP 的方法快速。另外,ICP 方法虽然可以对点云的尺度比进行估计,但是初始的点云位姿非

常重要。同时本实验的真实点云不能互相完整地重叠,所以 ICP 方法无法应用。




图6 SGICP 与 ICP 方法的收敛速度对比

我们将 SGICP 算法应用在比较有挑战性的数据上。我们使用 SfM(structure from motion)的方法构建了两个点云,分别包含 549 753 及 492 032 个 3D 点(如图 7(a) 所示)。基于 SfM 方法构建的 3D 点云无法得到统一的尺度值,并且包含大量的噪声及闭环点。但是使用我们的算法,可以准确对其进行配准。配准结果如图 7(b) 所示。




图7 SfM 点云及配准结果

3 结 语

本文提出了一种基于扩展 GICP 方法的点云配准以及点云尺度估计的方法。通过增加尺度变量重新设计了点云配准的成本函数,同时给出了新成本函数对于变换矩阵各分量的偏导值,应用于梯度下降、牛顿法等非线性优化方法中,得到了较好的结果。

但是本文的方法对于两点云尺度差别较大情况无法有效地配准。因为在这种情况下,SGICP 无法有效地查找高质量的对对应点并计算梯度。因此我们建议给出一个初始的粗尺度猜测再应用本算法。

## 参 考 文 献

- [1] Besl P J, McKay N D. A method for registration of 3-D shapes [J]. IEEE Transactions on Pattern Analysis & Machine Intelligence, 2002, 14(2): 239 - 256.
- [2] Hurley J R, Cattell R B. The procrustes program: Producing direct rotation to test a hypothesized factor structure [J]. Systems Research & Behavioral Science, 1962, 7(2): 258 - 262.
- [3] Dryden I L, Mardia K V. Statistical shape analysis [J]. John Wiley & Sons Ltd Chichester, 1998, 213(6): 663 - 669.
- [4] Zhang Z. Iterative Point Matching for Registration of Free-Form Curves Rapports de Recherche [R]. IRA Rapports de Recherche, Programme 4: Robotique, Imageet Vision, no. 1658, 1992.
- [5] Chen Y, Medioni G. Object modeling by registration of multiple range images [C]// IEEE International Conference on Robotics and Automation, 1991. Proceedings. IEEE, 2002: 145 - 155.
- [6] Segal A, Hähnel D, Thrun S. Generalized-ICP [C]// Robotics: Science and Systems V, University of Washington, Seattle, USA, June 28 - July 1, 2009.
- [7] Johnson A E, Hebert M. Surface matching for object recognition in complex three-dimensional scenes [J]. Image & Vision Computing, 1998, 16(9 - 10): 635 - 651.
- [8] Johnson A E, Hebert M. Using spin images for efficient object recognition in cluttered 3D scenes [J]. IEEE Transactions on Pattern Analysis & Machine Intelligence, 1999, 21(5): 433 - 449.
- [9] Radu B S, Rusu B, Konolige K, et al. NARF: 3D Range Image Features for Object Recognition [C]// Workshop on Defining and Solving Realistic Perception Problems in Personal Robotics at IROS, 2010.
- [10] Rusu R B, Marton Z C, Blodow N, et al. Persistent Point Feature Histograms for 3D Point Clouds [C]// Intelligent Autonomous Systems 10, IAS 2008. 2008: 119 - 128.
- [11] Rusu R B, Blodow N, Beetz M. Fast point feature histograms (FPFH) for 3D registration [C]// IEEE International Conference on Robotics and Automation. IEEE, 2009: 3212 - 3217.
- [12] Frome A, Huber D, Kolluri R, et al. Recognizing Objects in Range Data Using Regional Point Descriptors [M]// Computer Vision-ECCV 2004. Springer Berlin Heidelberg, 2004: 224 - 237.
- [13] Guo Y, Sohel F, Bennamoun M, et al. Rotational Projection Statistics for 3D Local Surface Description and Object Recognition [J]. International Journal of Computer Vision, 2013, 105(1): 63 - 86.
- [14] Scovanner P, Ali S, Shah M. A 3-dimensional sift descriptor and its application to action recognition [C]// Proceedings of the 15th International Conference on Multimedia 2007, Augsburg, Germany, September 24 - 29, 2007: 357 - 360.
- [15] Knopp J, Prasad M, Willems G, et al. Hough Transform and 3D SURF for Robust Three Dimensional Classification. [C]// Computer Vision-ECCV 2010-, European Conference on Computer Vision, Heraklion, Crete, Greece, September 5 - 11, 2010, Proceedings. DBLP, 2010: 589 - 602.
- [16] Tombari F, Salti S, Stefano L D. Unique Signatures of Histograms for Local Surface Description [M]// Computer Vision - ECCV 2010. Springer Berlin Heidelberg, 2010.
- [17] Lin B, Zhao F, Tamaki T, et al. SIPF: Scale invariant point feature for 3D point clouds [C]// IEEE International Conference on Image Processing. IEEE, 2015.
- [18] Lin B, Wang F, Sun Y, et al. Boundary points based scale invariant 3D point feature [J]. Journal of Visual Communication & Image Representation, 2017, 48: 136 - 148.
- [19] Huang X. Learning a 3D descriptor for cross-source point cloud registration from synthetic data [DB]. eprint arXiv: 1708.08997, 2017.
- [20] Lin C C, Tai Y C, Lee J J, et al. A novel point cloud registration using 2D image features [J]. Eurasip Journal on Advances in Signal Processing, 2017, 2017(1): 5.
- [21] Elbaz G, Avraham T, Fischer A. 3D Point Cloud Registration for Localization Using a Deep Neural Network Auto-Encoder [C]// Computer Vision and Pattern Recognition. 2017.
- [22] Lin B, Tamaki T, Slomp M, et al. 3D Keypoints Detection from a 3D Point Cloud for Real-Time Camera Tracking [J]. Ieee Transactions on Electronics Information & Systems, 2013, 133(1): 1 - 7.
- [23] Aubry M, Maturana D, Efros A A, et al. Seeing 3D Chairs: Exemplar Part-Based 2D-3D Alignment Using a Large Dataset of CAD Models [C]// Computer Vision and Pattern Recognition. IEEE, 2014: 3762 - 3769.
- [24] Crivellaro A, Lepetit V. Robust 3D Tracking with Descriptor Fields [C]// Computer Vision and Pattern Recognition. IEEE, 2014: 3414 - 3421.
- [25] Lin B, Tamaki T, Raytchev B, et al. Scale ratio ICP for 3D point clouds with different scales [C]// IEEE International Conference on Image Processing. IEEE, 2014: 2217 - 2221.
- [26] Lin B, Tamaki T, Zhao F, et al. Scale alignment of 3D point clouds with different scales [J]. Machine Vision & Applications, 2014, 25(8): 1989 - 2002.
- [27] Mellado N, Dellepiane M, Scopigno R. Relative scale estimation and 3D registration of multi-modal geometry using Growing Least Squares. [J]. IEEE Transactions on Visualization & Computer Graphics, 2016, 22(9): 2160 - 2173.
- [28] The Stanford 3D Scanning Repository [EB/OL]. <http://www.graphics.stanford.edu/data/3Dscanrep/>.